7 SUPERINTELLIGENZ, SINGULARITÄT UND MASCHINENETHIK



7.1 SUPERINTELLIGENZ UND SINGULARITÄT

In den vorangehenden Kapiteln lag der Schwerpunkt auf schwacher KI, die nicht das Ziel verfolgt, mit KI-Algorithmen das Niveau menschlicher Intelligenz im Handeln und Denken zu erreichen oder sogar zu übertreffen. Insbesondere Maschinenlernen und Deep Learning beschränken sich auf schwache KI. Der ursprüngliche Anspruch der KI-Gründer in den 1950er Jahren war die starke KI, konnte aber nicht mit symbolverarbeitender KI erreicht werden. Das Thema ist allerdings nicht verschwunden aus der KI-Welt, sondern wird unter den Begriffen Superintelligenz und Singulärität weiter diskutiert.

»Unter einer Superintelligenz wird ein KI-System verstanden, das der individuellen und kollektiven menschlichen Intelligenz überlegen ist.« (Mainzer 2016: 210) Aus dieser Definition lässt sich Singularität als zukünftiger Zeitpunkt ableiten: »Unter technologischer Singularität wird der Zeitpunkt der Entstehung einer Superintelligenz verstanden.« (2016: 211) Der Singularitätsbegriff bedeutet in der Astrophysik das Erreichen eines schwarzen Lochs, innerhalb dessen die normalen Gesetze der Physik zusammenbrechen. Bereits 1964 prognostizierte der Mathematiker Irving John Good: »Die erste ultraintelligente Maschine ist also die letzte Erfindung, die der Mensch je machen muss, vorausgesetzt, die Maschine ist fügsam genug, uns zu sagen, wie man sie unter Kontrolle hält.« (Good, zitiert aus Bostrom 2016: 17–18)

Ein weiterer Begriff in diesem Zusammenhang ist *Transhumanismus:* »Transhumanismus will die Grenzen des menschlichen Organismus durch Technologie überwinden. Jenseits der technologischen Singularität wird eine Superintelligenz die Entwicklung des Menschen steuern.« (Main-

zer 2016: 212) Diese Vision einer Intelligenz von Maschinen, die über die menschliche Intelligenz hinausgeht, hat der Mathematiker Vernor Vinge bereits 1993 veröffentlicht: »... innerhalb der nächsten dreißig Jahre werden wir die technologischen Mittel haben, um superhumane Intelligenz (Superhuman Intelligence) zu entwickeln. Kurz danach wird das Ende der menschlichen Ära erreicht sein.« (Vinge, zitiert aus Ford 2016: 229; Übersetzung des Verf.)

Ray Kurzweil (2014) hat sich in dem Buch Menschheit 2.0. Die Singularität naht (The Singularity is Near: When Humans Transcend Biology) intensiver mit den Merkmalen der Singularität beschäftigt. Seine Definition von Singularität beinhaltet nicht das Ende der menschlichen Entwicklung, aber eine radikale Veränderung: »Es handelt sich (bei Singularität) um einen zukünftigen Zeitabschnitt, in dem der technische Fortschritt so schnell und seine Auswirkungen so tiefgreifend sein werden, dass das menschliche Leben einen unwiderruflichen Wandel erfährt.« (Kurzweil 2014: 7).

Kurzweil fasst die drei Merkmale zusammen, die menschliche Intelligenz auszeichnen: »Zu den menschlichen Stärken gehört eine große Begabung zur Mustererkennung. Die massive Parallelität und autonome Organisation des Gehirns sind optimale Voraussetzungen für das Erkennen von versteckten Regelmäßigkeiten im Chaos. Des Weiteren können Menschen aus Erfahrung lernen, daraus Schlüsse ziehen und Prinzipien ableiten. Eine menschliche Schlüsselkompetenz besteht darin, mentale Abbilder der Realität zu erstellen, sie zu variieren und Gedankenexperimente durchzuführen.« (2014: 26–27)

Die drei Stärken von Maschinen sind erstens die hohe Fähigkeit zum Speichern und Abrufen von Fakten, zweitens die Fähigkeit, einmal Erlerntes beliebig oft anzuwenden, und drittens die Fähigkeit, ihr Wissen extrem schnell zu kommunizieren (2014: 27). Kurzweil vertritt die These, dass sich diese Stärken von Menschen und Maschinen zu einer *Mensch-Maschine-Zivilisation* kombinieren werden: »Die Maschinen werden menschlich sein, auch wenn sie es nicht biologisch sind; ... der Menschheitsbegriff wird sich jedoch von seinen biologischen Wurzeln lösen.« (2014: 31) Schmidhuber prognostiziert, dass nach der Singularität die Mensch-Maschine-Intelligenz das gesamte Weltall durchdringen wird (2017).

Kurzweils zeitliche Prognosen, dass es bis Mitte der 2020er Jahre »funktionierende Nachbildungen der menschlichen Intelligenz« geben und die Singularität um 2045 eintreten wird, war wie viele Vorhersagen von KI-Experten zu optimistisch. Es ist nach dem Stand der KI-Forschung noch nicht erwiesen, dass Transhumanismus mit KI-Systemen überhaupt